

线性分类器（逻辑回归 & GDA 高斯判别分析）

在这个问题中，我们将讨论迄今为止课上涉及到的两种概率线性分类器。第一种是判别式线性分类器：逻辑回归，第二种是生成式线性分类器：高斯判别分析（GDA）。这两种算法都能找到将数据分为两类的线性决策边界，但各自具有不同的假设条件。在这个问题中，我们将深入了解这两种算法的异同，以及它们的优缺点。

对于这个问题，我们考虑以下两个数据集：

i. `data/ds1_{train,valid}.csv`

ii. `data/ds2_{train,valid}.csv`

每个文件包含 m 个示例，每行表示一个示例 $(x^{(i)}, y^{(i)})$ 。其中，第 i 行包含 $x_0^{(i)} \in R$, $x_1^{(i)} \in R$ 和 $y^{(i)} \in \{0,1\}$ 三列。在下列问题中，我们将使用逻辑回归和高斯判别分析（GDA）对这两个数据集进行二元分类。

1. 在课上，我们学习了逻辑回归的平均经验损失：

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})),$$

其中， $y^{(i)} \in \{0,1\}$, $h_{\theta}(x) = g(\theta^T x)$, $g(z) = 1/(1 + e^{-z})$ 。

求该函数的 Hessian H ，并证明对于任意向量 z ，以下条件成立：

$$z^T H z \geq 0$$

提示：可以先证明 $\sum_i \sum_j z_i x_i x_j z_j = (x^T z)^2 \geq 0$, $g'(z) = g(z)(1 - g(z))$ 。

备注：这是证明矩阵 H 是正半定矩阵的标准方法之一，记作 " $H \succeq 0$ "。这意味着 J 是凸的，除了全局最小值外，没有局部最小值。当然也可以选择使用其他方法来证明 $H \succeq 0$ 。

2. 【代码题】根据 `src/p01b_logreg.py` 中的要求，使用牛顿法训练逻辑回归分类器。从 $\theta = \vec{0}$ 开始，使用牛顿法，直到 θ 的更新很小为止。具体来说，训练到第 k 轮，使得 $\|\theta_k - \theta_{k-1}\|_1 < \varepsilon$, $\varepsilon = 1 \times 10^{-5}$ 。请确保将模型预测结果写入代码中所指定的文件中。

3. 在 GDA 中，我们用以下方程对 (x, y) 的联合分布进行建模：

$$\begin{aligned} p(y) &= \begin{cases} \phi & \text{if } y = 1 \\ 1 - \phi & \text{if } y = 0 \end{cases} \\ p(x|y=0) &= \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_0)^T \Sigma^{-1} (x - \mu_0)\right) \\ p(x|y=1) &= \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_1)^T \Sigma^{-1} (x - \mu_1)\right) \end{aligned}$$

其中， $\phi, \mu_0, \mu_1, \Sigma$ 为模型参数。

假设我们已经对参数 $\phi, \mu_0, \mu_1, \Sigma$ 进行了拟合，现在想对一个新的数据点 x 所对应的 y 进行预测。为了证明 GDA 所产生的分类器具有线性判定边界，试说明后验分布可以写成：

$$p(y=1 | x; \phi, \mu_0, \mu_1, \Sigma) = \frac{1}{1 + \exp(-(\theta^T x + \theta_0))}$$

其中, $\theta \in R^n$, $\theta_0 \in R$, 且为 $\phi, \mu_0, \mu_1, \Sigma$ 的函数。

4. 对这一小问, 假设 n (x 的维数) 为 1, 那么 $\Sigma = [\sigma^2]$ 为实数, 并且 Σ 的行列式可以由 $|\Sigma| = \sigma^2$ 得到。基于给定的数据集, 可以得到参数 $\phi, \mu_0, \mu_1, \Sigma$ 的最大似然估计值为:

$$\begin{aligned}\phi &= \frac{1}{m} \sum_{i=1}^m 1\{y^{(i)} = 1\} \\ \mu_0 &= \frac{\sum_{i=1}^m 1\{y^{(i)} = 0\} x^{(i)}}{\sum_{i=1}^m 1\{y^{(i)} = 0\}} \\ \mu_1 &= \frac{\sum_{i=1}^m 1\{y^{(i)} = 1\} x^{(i)}}{\sum_{i=1}^m 1\{y^{(i)} = 1\}} \\ \Sigma &= \frac{1}{m} \sum_{i=1}^m (x^{(i)} - \mu_{y^{(i)}})(x^{(i)} - \mu_{y^{(i)}})^T\end{aligned}$$

对数似然函数为:

$$\begin{aligned}\ell(\phi, \mu_0, \mu_1, \Sigma) &= \log \prod_{i=1}^m p(x^{(i)}, y^{(i)}; \phi, \mu_0, \mu_1, \Sigma) \\ &= \log \prod_{i=1}^m p(x^{(i)} | y^{(i)}; \mu_0, \mu_1, \Sigma) p(y^{(i)}; \phi)\end{aligned}$$

通过最大化 ℓ , 证明 $\phi, \mu_0, \mu_1, \Sigma$ 的最大似然估计值确实可以由上述公式表示。

(可以假设至少有一个正例和一个负例, 从而确保上述对 μ_0 和 μ_1 的定义中分母不为零)

5. **【代码题】** 在 `src/p01e_gda.py` 中填写代码计算 $\phi, \mu_0, \mu_1, \Sigma$, 推导 θ , 并使用得到的 GDA 模型对验证集进行预测。

6. 对于第一个数据集, 绘制训练数据图, 横轴为 x_1 , 纵轴为 x_2 , 并使用不同的符号对 $y^{(i)} = 0$ 和 $y^{(i)} = 1$ 两个类别的示例 $x^{(i)}$ 进行表示。在同一张图上, 绘制第 2 问中通过逻辑回归找到的决策边界。此外, 再绘制一张同样的训练数据图, 绘制第 5 问中通过 GDA 找到的决策边界。

7. 对于第二个数据集, 重复第 6 问中的步骤。在哪个数据集上, GDA 的表现不如逻辑回归? 为什么会出现这种情况?

8. 对于 GDA 在第 6 问和第 7 问中表现较差的数据集, 你能否找到一种对 $x^{(i)}$ 的变换, 使 GDA 的表现明显变得更好? 这种变换是什么?